

Exercício Visão Computacional

Parte prática

Este exercício é sobre SIFT (Scale Invariant Feature Transform)

Ao final do exercício você deve costurar duas (ou mais) imagens obtidas por fotografias de um panorama com a posição da câmera no mundo um pouco deslocada (um pequeno giro da câmera, por exemplo). Você pode usar as imagens fornecidas como anexo a este exercício ou imagens que você mesmo capturar/escolher.

- 1) Use o SIFT para detectar os pontos de interesse e seus descritores nas duas imagens.
- 2) Exiba os pontos encontrados com círculos cujo tamanho indique a escala em uma das imagens. Sugestão: você pode usar a função `cv2.drawKeypoints`.
- 3) Escolha um ponto de interesse encontrado pelo SIFT em uma das imagens e exiba as informações deste ponto de interesse:

- `pt`: Tupla contendo as coordenadas (x, y) do ponto de interesse.
- `size`: Valor que representa a escala do ponto.
- `angle`: Ângulo de orientação do ponto.
- `response`: Valor de resposta (relacionado à “qualidade” do ponto).
- `octave`: Número da oitava onde foi encontrado.

- 4) Determine a correspondência entre os pontos encontrados.

Sugestão: ao invés por força bruta (todos os pontos contra todos os pontos) você pode usar `cv2.FlannBasedMatcher`.

```
flann = cv2.FlannBasedMatcher(index_params, search_params)
```

```
correspondencias = flann.knnMatch(descritores1, descritores2, k=2)
```

Este trecho do código encontra os melhores pares de forma eficiente.

- 5) Estime a transformação projetiva H que leva pontos de destaque de uma imagem em seus correspondentes na outra imagem, usando o método RANSAC.

Sugestão: você pode usar a função `cv2.findHomography(pontos2, pontos1, cv2.RANSAC, 5.0)`, que já usa o método RANSAC para encontrar a transformação projetiva que melhor um conjunto de pontos *alvo* ao conjunto de pontos *origem*.

- 6) Transforme uma das imagens segundo a transformação projetiva H e costure as imagens para gerar uma imagem única.

Sugestão: use

```
imagem_unida = cv2.warpPerspective(imagem2, matriz_homografia,  
(imagem1.shape[1] + imagem2.shape[1], imagem1.shape[0]))
```

```
imagem_unida[0:imagem1.shape[0], 0:imagem1.shape[1]] = imagem1
```

para transformar a imagem (warping) e costurar duas imagens.

Parte teórica

Nesta parte vamos considerar a imagem em tons de cinza como uma função $I: \mathbb{R}^2 \rightarrow \mathbb{R}$ suave (isto é, infinitamente diferenciável). O espaço de escala é uma família de imagens $\hat{I}(t) = L(I, t)$, ($t \geq 0$) onde a primeira imagem da família é a própria imagem original, ou seja, $\hat{I}(0) = L(I, 0) = I$.

A família de imagens é obtida por convolução com gaussianas de variâncias iguais à escala. Logo, $\hat{I}(x, y, t) = (g(t) * I)(x, y)$. Esta convolução, como sabemos, é calculada pela integral $\hat{I}(x, y, t) = \iint_{\mathbb{R}^2} g(s, r, t) \cdot I(s - x, r - y) ds dr$, onde $g(x, y, t)$ é a função gaussiana com média (0,0) com variância t : $g(x, y, t) = \frac{1}{2\pi t} e^{-\frac{x^2+y^2}{2t}}$. Isto é equivalente a dizer que a família de imagens $\hat{I}(t)$ é a solução da equação do calor com valor inicial:

$$\begin{cases} \hat{I}_t(x, y, t) = \hat{I}_{xx}(x, y, t) + \hat{I}_{yy}(x, y, t) \\ \hat{I}(x, y, 0) = I(x, y) \end{cases}$$

Uma abordagem alternativa para os espaços de escala é axiomática. São descritas propriedades desejáveis que os espaços de escala devem possuir se conclui que a transformação $L(I, t)$ que satisfaz estas propriedades é a convolução com a gaussiana.

Algumas das propriedades são:

- Linearidade: $a \cdot \hat{I}_1(t) + b \cdot \hat{I}_2(t) = L(aI_1 + bI_2)$
- Invariância por translação: $\hat{I}(x - \Delta x, y - \Delta y, t) = L(I(x - \Delta x, y - \Delta y), t)$
- Propriedade de semigrupo: $L(I, t + s) = L(L(I, t), s)$
- Não ampliação de máximos (e mínimos) espaciais:
 - $\partial_t \hat{I}(x_*, y_*, t) \leq 0$ se (x_*, y_*) for um ponto de máximo.
 - $\partial_t \hat{I}(x_*, y_*, t) \geq 0$ se (x_*, y_*) for um ponto de mínimo.
- Invariante por rotação: o espaço de escala de uma imagem rotacionada é a rotação do espaço de escala da imagem original.

(Uma lista completa, com 9 axiomas, pode ser encontrada no artigo Lindeberg, T. Invariance of visual operations at the level of receptive fields, PLoS ONE, 2013 – ou no Wikipedia, claro!)

Neste exercício você deve mostrar que fazendo $L(I, t) = g(t) * I$, onde $g(t)$ é a gaussiana com variância t , as 5 propriedades listadas acima são satisfeitas.